01 결론 먼저

받을 필요가 없다. 4,000만 행짜리 표 하나만 있으면 된다.

결론

MIMIC-IV-ECHO에서 **DICOM 52만 파일은 이번 연구에 불필요**하다. 측정값은 `structured_measurement.csv` 한 파일에 있고, 요약 테이블은 BigQuery로 질의할 수 있다. 주제는 **경증 판막질환의 예후**를 1순위로 잡는다 — 변수 가용성이 가장 높고, "경증이라도 추적해야 하나"라는 임상 질문이 명확하다.

이 문서는 PhysioNet 계정은 있으나 데이터 용량 때문에 막힌 상황을 전제로, ① 받지 않고 쓰는 3가지 경로 ② 그 데이터로 되는 주제 5개 ③ 12주 실행안을 담는다.

02 진단

막힌 것은 데이터가 아니라 "다운로드"라는 가정이다

206,488
검사 (structured)
TTE 179,928 · stress 16,389 · TEE 10,171

91,372
환자
MIMIC-IV 임상DB와 subject_id 연결

524,137
DICOM 파일
7,228 검사 · 4,572명 — 이번엔 불필요

180–230
측정/검사
long format, 1행 = 1측정

문제의 실체

- 용량의 99%는 **DICOM 이미지**다. 52만 파일, 수백 GB.
- 정작 분석에 쓰는 값은 **카디올로지스트가 기록한 숫자**다.
- 즉 "전체 다운로드"는 연구 설계상 **과잉**이다.

추가로 확인된 제약

- 일부(769검사/437명)는 **hidden test set**으로 withheld — 전체 모집단이 아님.
- DICOM과 측정값을 잇는 직접 ID가 없어 **±2일 시간 연결** 테이블을 따로 제공.
- 2026년 Nature Sci Data 논문으로 공식 기술 — 인용 근거가 명확.

출처: **PhysioNet MIMIC-IV-ECHO v1.0.1** 데이터 기술 페이지 · Gow et al., Sci Data 2026

03 해법

받지 않고 쓰는 세 가지 경로 — 위에서부터 시도

접근 경로

경로	무엇을 하는가	판정
A. BigQuery 질의	PhysioNet 공개 BigQuery에 요약 테이블이 안내되어 있다. 필요한 컬럼만 SQL로 뽑아 CSV 수십 MB로 내려받는다.	1순위 데이터 이동 0
B. CSV만 선택 다운로드	`structured_measurement.csv` + `echo-study-list.csv` + `echo-record-list.csv`. `files/` 디렉터리는 받지 않는다.	현실적 수 GB 이내
C. 부분 DICOM	영상이 꼭 필요할 때만 subject_id 단위로 소량. 예: 측정 신뢰도 검증용 100검사.	3순위 영상연구 아니면 불필요

왜 BigQuery가 답인가

long format은 검사 1건당 200행이다. 2억 행을 로컬로 가져오면 노트북이 죽는다. SQL로 `WHERE measurement_description IN (...)` 필터를 걸면 **분석에 쓰는 표는 수십만 행**으로 줄어든다. 즉 다운로드 문제가 사라진다.

먼저 할 30분

BigQuery 콘솔에서 `SELECT measurement_description, count(*)` 한 줄로 **변수 인벤토리**를 뽑는다. 이 표가 이후 모든 설계의 근거가 된다. 접속 경로·데이터셋 이름은 계정 로그인 후 확인 필요.

04 데이터 구조

변수는 "이름"이 아니라 "설명"으로 찾는다

`structured_measurement.csv`의 컬럼은 8개뿐이다. 값은 전부 long format으로 쌓여 있다.

STRUCTURED_MEASUREMENT.CSV

컬럼	의미
subject_id	MIMIC-IV 전체와 공통인 환자 ID — 사망·진단·검사 연결 키
measurement_id	검사 1건 식별자 (한 검사의 200여 행이 같은 값)
measurement_datetime	비식별화된 검사 시각 — 시간순·생존분석 기준
test_type	TTE / TEE / stress — **TTE만 쓰면 모집단이 깨끗해진다**
measurement / measurement_description	측정 항목 ID와 이름 — **여기서 변수를 고른다**
result / unit	값과 단위. 단위가 섞여 있으므로 반드시 unit으로 교차 확인

실무 팁 — `result`는 문자열로 저장된 경우가 있어 숫자 캐스팅 전에 이상값(`<10`, `N/A`, 공백)을 먼저 세야 한다. 버전 간 변수명 변경도 있으니 전처리 스크립트에 매핑 테이블을 두는 게 안전하다.

05 함정

이 데이터셋의 진짜 위험은 결측이 아니라 "결측처럼 보이는 것"

소스 시스템이 중간에 바뀌었다

연구 기간 중 심초음파 랩 시스템이 교체되어 **같은 개념의 변수명이 달라졌다**. 공식 문서의 예: 한 시스템은 `lvef` · `lvef_upper`, 다른 시스템은 `biplane_lvef` · `lvef_3d`.

따라서 **변수가 없는 것은 임상적 결측이 아닐 수 있다**. 이걸 무시하면 "E/e′는 30%만 기록되었다"는 결론이 사실은 "구 시스템에는 그 변수 자체가 없었다"가 된다.

그래서 설계에 반드시 넣을 것

- 검사일 기준 **시대 구분(era) 변수**를 만들고, 시대별 변수 가용성 표를 먼저 출력한다.
- 주 분석은 **변수가 양쪽 시대에 모두 존재하는 항목**으로 한정한다.
- 민감도 분석: era를 층화하거나 상호작용항으로 넣는다.
- 이 표 자체를 **보충자료 1**로 넣으면 심사에서 신뢰를 얻는다.

> 이 함정이 곧 두 번째 논문
>
> "소스 시스템 전환으로 인한 변수 부재가 심초음파 역학 연구의 결론을 바꾸는가" — 아직 정리된 사례가 드문 방법론 주제다. 다만 JCVI보다는 의료정보학 저널이 맞다.

06 주제 후보

되는 주제 5개 — 변수 가용성과 임상 질문으로 줄 세운다

후보 · 근거 · 판정

주제	핵심 질문	필요 변수	판정
T1. 경증 판막질환의 예후	경증 AS·MR·TR은 정말 양성인가? 중등도로 진행하지 않아도 사망과 연관되는가	판막별 중증도 등급, 대동맥 판막 속도·평균압력차, LVEF	1순위
T2. E/e′와 사망	LVEF 보존군에서 E/e′ 상승이 독립적 예후인자인가	E/e′, E/A, TR velocity, LA 용적, LVEF	2순위 가용성 확인 필요
T3. LVEF와 사망의 U자	HFmrEF 구간이 가장 나쁜가, 아니면 저LVEF가 단조증가인가	LVEF, 사망일	경쟁 많음
T4. 우심실 기능	TAPSE 저하가 좌심 기능과 독립적으로 사망을 예측하는가	TAPSE, RVSP, RV 크기	가용성 변동
T5. 대동맥근 확장	무증상 대동맥근 확장의 유병률과 예후	대동맥근 직경, 판막 상태	단일기관 한계

판정 기준 — ① 변수 기록률 ② 임상적 행동 변화 유도 여부 ③ JCVI 심사에서 "한국 일반화" 질문을 견딜 수 있는가. 변수명은 접속 후 인벤토리로 확정하며, 이 표의 변수는 **표준 심초음파 측정 항목 기준 추정**이다.

07 1순위 설계

T1 — "경증"이라는 라벨을 다시 심판한다

PICO

P	TTE 시행 성인, 판막 중증도 경증으로 판정된 군 (AS / MR / TR 각각)
E	경증 판막질환 vs 정상 판막
C	같은 코호트 내 판막 정상군
O	1차: 전원 사망. 2차: 심부전 입원, 중등도 이상 진행(반복 초음파가 있는 경우)

분석

- Cox 비례위험, era·나이·성·LVEF·eGFR·동반판막질환 보정
- 경증 단독 vs 경증 중복(2개 이상) 군 비교 — **여기가 새로움**
- 경쟁위험(비심장 사망) 모형을 민감도 분석으로
- 표 3개 · 그림 2개(생존곡선, 판막별 forest)

> 왜 이 주제인가
>
> 경증 판막질환은 검진·외래에서 **"경증이니 1년 뒤 보자"**로 끝나는 가장 흔한 장면이다. 그 관행이 데이터로 지지되는지 묻는 논문은 임상의가 바로 인용한다. 심초음파학회지 독자와 정확히 겹친다.

08 사전부검

실패한다면 이 다섯 가지 때문이다

① 판막 중증도가 등급이 아니라 텍스트
판독문 자유기술로만 남아 있으면 등급 변수가 없다. → 인벤토리에서 등급형 변수 존재를 먼저 확인. 없으면 T2로 즉시 전환.

② 시대 불균형
구 시스템 시대에 경증 라벨이 몰려 있으면 시대가 교란변수가 된다. → 시대 층화 + 상호작용항.

③ 반복 초음파 결측
"진행"을 2차 결과로 잡으면 표본이 급감한다. → 진행은 exploratory로만 두고 1차는 사망.

④ 교란 by indication
초음파를 찍은 이유 자체가 예후다. → 입원·응급 vs 외래 strata, Charlson 보정, E-value 제시.

⑤ 단일기관·미국 코호트
심사에서 일반화 가능성을 반드시 묻는다. → 서론에서 한국 판막질환 역학 문헌과 대조, 한계 절에 명시.

게이트 — ①이 해결되지 않으면 12주 계획 전체를 T2로 갈아탄다. 판정은 인벤토리 확인 후 **3일 이내**에 한다.

09 실행

12주 — 8주에 초록, 11주에 투고

W0 — **접근 확정**
PhysioNet DUA 확인 → BigQuery 접속 또는 CSV 선택 다운로드. CITI 교육 이수 상태 점검.

W1 — **변수 인벤토리 · GO/NO-GO**
`measurement_description` 빈도표 + 시대별 가용성 교차표. 판막 등급 변수 유무로 T1/T2 결정.

W2-3 — **코호트 정의**
TTE만, 성인, 판막질환별 경증군/정상군. 환자당 지수검사 1건만(중복검사 제거 규칙 명시).

W4-5 — **결과변수 · 공변량**
MIMIC-IV에서 사망일·입원·동반질환 추출. 결측 처리 규칙과 E-value 사전 계산.

W6-8 — **분석 · 초록**
Cox + 경쟁위험, 표 3개·그림 2개. 8주차에 학회 초록 초안 완성(KSE 2027 춘계 대비).

W9-11 — **원고 · JCVI 투고**
STROBE 체크리스트, 보충자료에 변수 인벤토리 표. 코드는 GitHub 공개(데이터는 DUA상 불가).

KSE 2027 — 2026 추계 초록은 9/28 마감으로 지났다. 다음 창은 2027 춘계(통상 5-6월, 초록 3-4월)이며 **정확한 일정은 학회 공지 확인 필요**.

10 다음 한 걸음

오늘 결정할 것 두 가지

결정 1 — 접근 경로
BigQuery 질의를 먼저 시도한다. 막히면 CSV 선택 다운로드로 내려간다. 어느 쪽이든 **DICOM은 받지 않는다**.

결정 2 — 1순위 주제
T1(경증 판막질환)으로 간다. 단, **W1 인벤토리에서 판막 등급 변수가 없으면 T2(E/e′)** 로 즉시 전환한다.

지금 30분 안에 하는 일

1. BigQuery 콘솔에서 `measurement_description` 빈도 상위 100개를 뽑는다.
2. 그 안에 판막 중증도·E/e′·TAPSE가 있는지 눈으로 확인한다.
3. 결과에 따라 T1 또는 T2로 확정하고, 이 문서의 07장을 그 주제로 고쳐 쓴다.

한 줄

용량 문제는 이미 해결되어 있다. 남은 리스크는 기술이 아니라 **변수 인벤토리를 언제 보느냐**다.